

École Marocaine des Sciences de l'Ingénieur

EMSI Casablanca

4ème année — Intelligence Artificielle & Data Science

Année académique 2025–2026

DATA MINING — PROJET 11

Segmentation RFM de clients e-commerce

Une approche de clustering non supervisé

Online Retail Dataset — UCI Machine Learning Repository (2010–2011)

Réalisé par :

Abderrhmane El Idrissi

Badreddine Iksi

Abdellah Mamdouh

Encadré par :

Pr. Youssef Sekhara

EMSI Casablanca

Domaine : E-commerce & Segmentation client

Table des matières

1 Introduction	3
1.1 Contexte et problématique	3
1.2 Objectifs.....	3
1.3 Plan du rapport	3
2 Présentation du dataset	4
2.1 Source et description	4
2.2 Structure du jeu de données.....	4
2.3 Qualité des données brutes	4
3 Nettoyage et prétraitement transactionnel.....	5
3.1 Étapes de nettoyage	5
3.2 Construction de la variable TotalPrice.....	5
3.3 Vérification de cohérence.....	5
4 Construction des indicateurs RFM.....	6
4.1 Définitions et date de référence	6
4.2 Statistiques descriptives RFM	6
4.3 Distribution des variables RFM.....	6
4.4 Transformation logarithmique.....	7
5 Préparation des données pour le clustering.....	8
5.1 Standardisation.....	8
5.2 Choix du nombre de clusters k.....	8
6 Modélisation : K-Means	10
6.1 Entraînement et tailles des clusters	10
6.2 Projection 2D (ACP) des clusters.....	10
6.3 Profils RFM par cluster	10
7 Interprétation métier et plan d'action.....	12
7.1 Règles de classification	12
7.2 Segments obtenus	12
7.3 Plan d'action marketing.....	13
8 Extension : clustering hiérarchique	14
8.1 Dendrogramme.....	14
8.2 Comparaison K-Means vs Ward	14
9 Conclusion.....	16
9.1 Synthèse des résultats	16
9.2 Limites et perspectives	16

1. Introduction

1.1 Contexte et problématique

Les entreprises de e-commerce disposent aujourd'hui d'historiques transactionnels massifs, mais l'ensemble de leur clientèle n'adopte pas le même comportement d'achat : certains clients achètent fréquemment et récemment, d'autres une seule fois il y a longtemps. Le Online Retail Dataset, collecté par un détaillant en ligne basé au Royaume-Uni entre décembre 2010 et décembre 2011, recense l'ensemble des transactions effectuées par ses clients.

Problématique centrale. Comment segmenter les clients selon leur Récence, leur Fréquence et leur Montant d'achat (méthode RFM) afin d'en tirer des actions marketing ciblées ? Quelle méthode de clustering permet d'obtenir des segments à la fois statistiquement valides et exploitables d'un point de vue métier ?

1.2 Objectifs

1. Charger et explorer le dataset UCI Online Retail (id=352).
2. Nettoyer les données transactionnelles (CustomerID manquants, annulations, quantités/prix invalides).
3. Construire les indicateurs RFM (Récence, Fréquence, Montant) par client.
4. Transformer et standardiser les variables RFM pour le clustering.
5. Déterminer un nombre de clusters k justifié (coude, silhouette, granularité métier).
6. Entraîner un modèle K-Means et le comparer à un clustering hiérarchique (Ward).
7. Traduire les clusters en segments métier et proposer un plan d'action marketing.

1.3 Plan du rapport

Le chapitre 2 présente le dataset ; le chapitre 3 détaille le nettoyage transactionnel ; le chapitre 4 construit les indicateurs RFM ; le chapitre 5 prépare les données pour le clustering ; le chapitre 6 décrit la modélisation K-Means ; le chapitre 7 interprète les segments obtenus ; le chapitre 8 compare K-Means à un clustering hiérarchique ; le chapitre 9 conclut.

2. Présentation du dataset

2.1 Source et description

Le dataset provient du UCI Machine Learning Repository (identifiant id=352), chargé directement via le package officiel ucimlrepo. Il couvre les transactions d'un détaillant en ligne basé au Royaume-Uni, principalement spécialisé dans la vente de cadeaux, entre le 1er décembre 2010 et le 9 décembre 2011.

2.2 Structure du jeu de données

Tableau 1 — Description des principales variables

Variable	Rôle	Description
InvoiceNo	Identifiant	Numéro de facture (6 chiffres). Préfixe 'C' = annulation.
StockCode	Identifiant	Code produit (article), 5 chiffres.
Description	Feature	Nom du produit.
Quantity	Feature	Quantité achetée par ligne de commande.
InvoiceDate	Date	Date et heure de la facture.
UnitPrice	Feature	Prix unitaire du produit (en livres sterling, GBP).
CustomerID	Clé	Numéro de client (5 chiffres).
Country	Feature	Pays de résidence du client.

Le dataset brut comporte **541 909 lignes et 8 colonnes**, représentant des lignes de commande (et non directement des clients). Les indicateurs RFM par client seront construits par agrégation après nettoyage.

2.3 Qualité des données brutes

L'examen du dataset révèle plusieurs anomalies typiques des données transactionnelles brutes, à traiter avant tout calcul du RFM.

Tableau 2 — Rapport de qualité des données brutes

Indicateur	Nombre	% du total
Lignes totales	541 909	100,00
Lignes sans CustomerID	135 080	24,93
Factures annulées (InvoiceNo commence par 'C')	9 288	1,71
Quantités négatives	10 624	1,96
Prix unitaire ≤ 0	2 517	0,46
Lignes dupliquées	5 268	0,97

Constat. Le jeu de données contient des factures annulées (retours/avoirs), des quantités négatives et quelques prix unitaires nuls ou négatifs (ajustements comptables, erreurs de saisie). Ces lignes ne représentent pas de véritables achats et doivent être éliminées avant le calcul du RFM, sous peine de fausser directement la Fréquence et le Montant.

3. Nettoyage et prétraitement transactionnel

3.1 Étapes de nettoyage

Le nettoyage est appliqué selon un ordre précis, avec traçabilité du nombre de lignes restantes à chaque étape :

1. Suppression des lignes sans CustomerID (impossible de les attribuer à un client).
2. Suppression des factures annulées (InvoiceNo préfixé par 'C') – ce sont des retours, pas des achats.
3. Suppression des quantités négatives ou nulles restantes.
4. Suppression des prix unitaires nuls ou négatifs (lignes non commerciales).
5. Suppression des doublons exacts.

Tableau 3 — Traçabilité du nettoyage transactionnel

Étape	Lignes restantes	Supprimées (cumul)
Avant nettoyage	541 909	0
Après suppression CustomerID manquant	406 829	135 080
Après suppression factures annulées	397 924	143 985
Après suppression quantités ≤ 0	397 924	143 985
Après suppression prix unitaire ≤ 0	397 884	144 025
Après suppression des doublons	392 692	149 217

Au final, **392 692 lignes** sont conservées (72,5 % du total), réparties sur **4 338 clients uniques**, sur la période du 2010-12-01 au 2011-12-09.

3.2 Construction de la variable TotalPrice

La variable $\text{TotalPrice} = \text{Quantity} \times \text{UnitPrice}$ représente le montant de chaque ligne de commande ; c'est la brique de base du calcul du Montant (Monetary). Sur les données nettoyées, TotalPrice varie de 0,00 à 168 469,60 £, avec une moyenne de 22,63 £ et une forte dispersion (écart-type 311,10 £), traduisant la présence de quelques très grosses commandes.

3.3 Vérification de cohérence

Avant de poursuivre, on vérifie qu'aucun client ne présente, après nettoyage, un Montant total négatif ou nul, ni une Fréquence nulle — ce qui indiquerait un nettoyage incomplet des annulations. Cette vérification est validée : 0 anomalie détectée sur les 4 338 clients.

4. Construction des indicateurs RFM

4.1 Définitions et date de référence

- **Récence (R)** : nombre de jours écoulés depuis le dernier achat du client jusqu'à une date de référence.
- **Fréquence (F)** : nombre de commandes distinctes (InvoiceNo uniques) passées par le client.
- **Montant (M)** : somme totale dépensée par le client (TotalPrice).

La date de référence retenue est le lendemain de la dernière transaction observée, soit le **10 décembre 2011**. Ce choix garantit une récence minimale de 1 jour pour le client ayant acheté le plus récemment. Le calcul aboutit à une table RFM de **4 338 clients**.

4.2 Statistiques descriptives RFM

Tableau 4 — Statistiques descriptives des variables RFM (échelles d'origine)

	Recency (j)	Frequency	Monetary (£)
count	4 338	4 338	4 338
mean	92,54	4,27	2 048,69
std	100,01	7,70	8 985,23
min	1,00	1,00	3,75
25%	18,00	1,00	306,48
50%	51,00	2,00	668,57
75%	142,00	5,00	1 660,60
max	374,00	209,00	280 206,02

4.3 Distribution des variables RFM




Figure 1 — Distributions brutes des variables RFM (Récence, Fréquence, Montant)

Les trois variables présentent une asymétrie positive marquée :

Tableau 5 — Coefficients d'asymétrie (skewness) des variables RFM

Variable	Skewness
Recency	1,25
Frequency	12,06
Monetary	19,33

Une minorité de très gros clients (achats très fréquents ou très coûteux) tire fortement les distributions de Fréquence et de Montant vers la droite. Cette asymétrie justifie une transformation logarithmique avant standardisation et clustering, condition nécessaire pour que K-Means (basé sur la distance euclidienne) ne soit pas dominé par ces quelques valeurs extrêmes.

4.4 Transformation logarithmique

La transformation $\log(1+x)$ (np.log1p) est appliquée à chaque variable, ce qui gère naturellement les petites valeurs (notamment Frequency, qui peut valoir 1).




Figure 2 — Distributions des variables RFM après transformation logarithmique

Les distributions obtenues sont nettement plus symétriques et les valeurs extrêmes sont compressées, ce qui rend les variables plus adaptées à une comparaison par distance euclidienne.

5. Préparation des données pour le clustering

5.1 Standardisation

K-Means reposant sur une distance euclidienne, la variable Monetary (échelle en centaines/milliers de livres) écraserait totalement Recency et Frequency sans mise à l'échelle commune. Les trois variables log-transformées sont donc standardisées (StandardScaler, moyenne 0, écart-type 1) — étape indispensable avant tout K-Means.

Après standardisation, les moyennes obtenues sont ≈ 0 et les écarts-types ≈ 1 pour les trois variables (R_scaled, F_scaled, M_scaled), confirmant la bonne exécution de l'étape.

5.2 Choix du nombre de clusters k

K-Means est entraîné pour $k = 2$ à 10, en relevant à chaque fois l'inertie (méthode du coude) et le score de silhouette.




Figure 3 — Méthode du coude et score de silhouette pour $k = 2$ à 10

Tableau 6 — Inertie et score de silhouette selon k

k	Inertie	Silhouette
2	6 483,6	0,4328
3	4 869,5	0,3365
4	3 939,0	0,3375
5	3 296,7	0,3162
6	2 855,8	0,3124
7	2 548,8	0,3092
8	2 336,3	0,3033
9	2 156,0	0,2811
10	2 005,7	0,2767

Choix justifié de k. La courbe du coude ne présente pas de coude unique très net (transition progressive), mais identifie une zone $k = 3$ à 5 au-delà de laquelle le gain marginal d'inertie devient faible. Le score de silhouette est maximal pour $k = 2$ (0,4328), mais cette valeur ne sépare que des clients actifs vs inactifs, sans granularité métier suffisante. On retient donc le meilleur $k \geq 3$ au sens de la silhouette, soit **$k = 4$ (silhouette = 0,3375)**, qui offre un compromis entre qualité statistique et exploitabilité métier.

6. Modélisation : K-Means

6.1 Entraînement et tailles des clusters

Le modèle final `KMeans(n_clusters=4, init='k-means++', n_init=10, random_state=42)` est entraîné sur les trois variables RFM standardisées. Le score de silhouette final obtenu est de **0,3375**.

Tableau 7 — Taille des clusters K-Means ($k = 4$)

Cluster	Nombre de clients
0	713
1	1 622
2	837
3	1 166
Total	4 338

6.2 Projection 2D (ACP) des clusters

Les variables RFM standardisées sont en 3 dimensions ; une Analyse en Composantes Principales (PCA) projette les clients sur 2 axes pour visualiser la séparation des clusters. Les deux premières composantes expliquent conjointement 93,9 % de la variance totale (PC1 = 75,1 %, PC2 = 18,8 %).




Figure 4 — Projection 2D (ACP) des 4 clusters K-Means

Les groupes apparaissent globalement distincts dans l'espace projeté, ce qui renforce la pertinence du clustering retenu.

6.3 Profils RFM par cluster

Pour interpréter les clusters d'un point de vue métier, on revient aux unités originales (jours, nombre de commandes, livres sterling), et non aux valeurs standardisées/log.

Tableau 8 — Profil moyen et médian par cluster (échelles d'origine)

Cluster	Nb clients	% clients	Récence moy.	Fréquence moy.	Montant moy.	Montant méd.
0	713	16,4	12,2 j	13,8	8 088,0 £	3 722,8 £
1	1 622	37,4	181,5 j	1,3	341,0 £	296,1 £
2	837	19,3	17,7 j	2,2	557,3 £	480,3 £
3	1 166	26,9	71,6 j	4,1	1 801,8 £	1 345,2 £




Figure 5 — Profil moyen RFM par cluster (barplots)




Figure 6 — Heatmap des profils RFM normalisés par cluster (z-score relatif au profil moyen)

Le cluster 0 se distingue par une récence très faible, une fréquence élevée et un montant moyen très supérieur aux autres : il s'agit des meilleurs clients. À l'inverse, le cluster 1 (le plus nombreux, 37,4 % de la base) présente une récence très élevée et une fréquence/montant faibles : ces clients n'ont quasiment plus acheté depuis longtemps.

7. Interprétation métier et plan d'action

7.1 Règles de classification

Plutôt qu'un simple classement global (qui pourrait confondre un client nouveau mais peu actif avec un client autrefois actif mais en décrochage), une classification par règles métier est appliquée au profil moyen (R, F, M) de chaque cluster, comparé à la médiane inter-clusters de chaque variable (Récence médiane = 44,6 j, Fréquence médiane = 3,1, Montant médian = 1 180 £).

Tableau 9 — Règles de classification métier des segments

Condition (vs médiane inter-clusters)	Segment attribué
Récence basse ET Fréquence haute ET Montant haut	Champions / Clients VIP
Récence basse ET Fréquence basse ET Montant bas	Nouveaux clients / Occasionnels
Récence haute ET Fréquence basse ET Montant bas	Clients hibernants / Perdus
Récence haute ET (Fréquence haute OU Montant haut)	Clients à risque
Autre cas	Clients fidèles

Cette approche est généralisable à n'importe quel k et reflète la logique RFM classique utilisée en CRM (segmentation de type Champions / Loyal / At Risk / Hibernating).

7.2 Segments obtenus

Tableau 10 — Segments métier obtenus (triés par montant moyen décroissant)

Segment	Nb clients	% base	Récence moy.	Montant moy.
Champions / Clients VIP	713	16,4	12 j	8 088 £
Clients à risque	1 166	26,9	72 j	1 802 £
Nouveaux clients / Occasionnels	837	19,3	18 j	557 £
Clients hibernants / Perdus	1 622	37,4	182 j	341 £




Figure 7 — Segments métier projetés sur les deux composantes principales

Lecture métier. Les Champions (16,4 % des clients) ont acheté en moyenne il y a 12 jours, près de 14 fois, pour un montant moyen de 8 088 £ : ils génèrent l'essentiel du chiffre d'affaires. À l'opposé, les clients hibernants/perdus (37,4 % de la base) n'ont pas acheté depuis 182 jours en moyenne et présentent une fréquence et un montant très faibles : un risque de churn déjà largement consommé.

7.3 Plan d'action marketing

Tableau 11 — Actions marketing recommandées par segment

Segment	Action marketing recommandée
Champions / Clients VIP	Programme de fidélité premium et avantages exclusifs (accès anticipé aux nouveautés, remises VIP). Objectif : maximiser la rétention et transformer ces clients en ambassadeurs (parrainage, avis clients).
Nouveaux clients / Occasionnels	Programme de bienvenue / onboarding (email de remerciement, guide produits, code promo sur le 2 ^e achat) pour accélérer la transition vers une fréquence d'achat plus régulière.
Clients à risque	Campagne de relance proactive avant le décrochage complet : email personnalisé, offre de réactivation à durée limitée, enquête de satisfaction.
Clients hibernants / Perdus	Campagne de réactivation (win-back) avec une offre forte et un message « vous nous manquez ». Si l'absence de réaction persiste, exclure ces contacts des campagnes coûteuses pour préserver le ROI.

8. Extension : clustering hiérarchique

8.1 Dendrogramme

Pour valider la robustesse de la segmentation, un clustering hiérarchique ascendant (Agglomerative Clustering, linkage de Ward) est entraîné sur les mêmes variables RFM standardisées.




Figure 8 — Dendrogramme du clustering hiérarchique (Ward) — vue tronquée aux 30 derniers regroupements

Le dendrogramme permet d'explorer des granularités alternatives ($k = 2$ à 6) sans ré-entraîner de modèle, et de repérer des paliers naturels de fusion ; il est utilisé ici comme validation croisée de la structure trouvée par K-Means.

8.2 Comparaison K-Means vs Ward

Tableau 12 — Comparaison des deux méthodes de clustering ($k = 4$)

Méthode	Score de silhouette
K-Means	0,3375
Clustering Hiérarchique (Ward)	0,2811

L'Adjusted Rand Index entre les deux partitions est de **0,4373** (1 = partitions identiques, 0 = aussi proche que deux partitions aléatoires) : un accord modéré, ni négligeable ni parfait.




Figure 9 — Comparaison visuelle K-Means vs Clustering Hiérarchique (Ward), projection ACP

Tableau 13 — Tableau croisé des affectations K-Means × Hiérarchique

K-Means \ Hiér.	0	1	2	3
0	0	342	31	340
1	1 306	0	316	0
2	408	277	152	0
3	2	143	1 018	3

Lecture de la comparaison. K-Means optimise directement l'inertie intra-cluster autour de centroïdes et produit des clusters de forme plus sphérique et de tailles plus équilibrées — bien adapté à des données RFM standardisées. Le clustering hiérarchique (Ward) ne nécessite pas de fixer k à l'avance et offre une structure multi-niveaux utile, mais ici avec un score de silhouette légèrement inférieur. Le tableau croisé montre un accord partiel, confirmant une cohérence globale entre les deux méthodes malgré un ARI modéré.

9. Conclusion

9.1 Synthèse des résultats

Ce projet a démontré la faisabilité d'une segmentation client actionnable à partir des seules variables transactionnelles RFM. Les principaux enseignements sont :

1. Le jeu de données brut (541 909 lignes) a été nettoyé pour obtenir une base de 392 692 achats réels exploitable par client (4 338 clients).
2. Les indicateurs RFM ont été calculés pour chaque client, puis transformés (log) et standardisés afin de neutraliser leur forte asymétrie et leurs échelles très différentes avant le clustering.
3. Le nombre de clusters $k = 4$ a été choisi de façon justifiée en combinant la méthode du coude, le score de silhouette et un critère de granularité métier minimale.
4. Les clusters obtenus ont été traduits en segments métier actionnables (Champions, à risque, nouveaux/occasionnels, hibernants), chacun associé à une action marketing concrète.
5. La comparaison avec un clustering hiérarchique (Ward) confirme partiellement la robustesse de la segmentation K-Means retenue (ARI = 0,44).

9.2 Limites et perspectives

Limites. Le RFM ne capture pas la diversité des produits achetés (catégories, marges), ni la saisonnalité des achats ; le périmètre géographique (essentiellement Royaume-Uni) limite la généralisation à d'autres marchés.

Perspectives. Enrichissement par des variables produits ou par une valeur vie client (CLV) prédictive ; segmentation par pays pour les marchés les plus représentés ; optimisation des hyperparamètres et test d'autres algorithmes (DBSCAN, Gaussian Mixture) ; suivi temporel de la migration des clients entre segments (analyse de cohortes).